PEMBELAJARAN MESIN

Panduan Tugas Proyek Individu

Daftar isi

1	Mengapa proyek ini ada	3
2	Topik dan dataset Anda	4
3	Peta jalan proyek	6
4	Panduan hands-on, tahap demi tahap	7
5	Luaran dan struktur laporan	14
6	Jadwal dan dua pertemuan kelas	15
7	Rubrik penilaian	16
8	Integritas akademik dan penggunaan AI	17
L	Lampiran: daftar periksa sebelum mengumpulkan	18

Cara memakai panduan ini

Bab 1–3 menjelaskan apa yang diminta dan mengapa. Bab 4 adalah panduan kerja: setiap tahap berisi penjelasan, diagram, dan potongan kode Python yang bisa langsung Anda sesuaikan dengan dataset masing-masing. Semua potongan kode sudah diuji dengan scikit-learn 1.9 dan imbalanced-learn 0.14.

1 Mengapa proyek ini ada

Proyek ini menguji satu kemampuan inti: membangun model yang benar-benar bekerja pada data baru, dan mampu membuktikannya.

Di kelas, kita sudah membahas bahwa belajar bagi mesin berarti menemukan fungsi yang **menggeneralisasi**, bukan menghafal data latih. Kita juga sudah melihat bagaimana model bisa gagal: terlalu sederhana (underfitting), terlalu menghafal (overfitting), atau tampak hebat karena evaluasinya bocor. Proyek ini meminta Anda mengalami semua itu langsung pada satu masalah nyata.

Anda akan bekerja **sendiri** pada satu topik dan satu dataset yang sudah ditetapkan untuk Anda. Prosesnya meniru alur kerja peneliti dan praktisi: merumuskan masalah, memahami data, merancang validasi, membangun baseline, mencoba model yang lebih kuat, lalu menganalisis secara jujur kapan dan mengapa model Anda salah.

> **Yang dinilai bukan angka akurasi tertinggi**
>
> Model sederhana yang dievaluasi dengan benar dan dianalisis secara tajam akan mendapat nilai lebih tinggi daripada model kompleks dengan skor 99% yang ternyata bocor. Bobot terbesar rubrik ada pada **skema validasi**, **evaluasi**, dan **analisis**.

Setelah menyelesaikan proyek ini, Anda mampu

1. Merumuskan masalah nyata sebagai tugas pembelajaran mesin, dengan data, target, dan ukuran keberhasilan yang jelas.
2. Membangun baseline dan model lanjutan, lalu menjustifikasi pilihannya.
3. Merancang skema validasi yang bebas kebocoran data dan sesuai struktur data.
4. Memilih metrik berdasarkan biaya kesalahan di domain masalah.
5. Mendiagnosis underfitting atau overfitting dan menerapkan regularisasi yang tepat.
6. Menganalisis kesalahan model, keterbatasan, dan risiko etisnya secara kritis.

Bobot dan durasi

Proyek ini berbobot **100%** dan dikerjakan sekitar **lima minggu**, ditutup dengan presentasi pada Pertemuan 15 dan pengumpulan laporan pada Pertemuan 16. Ada dua titik temu di kelas: **Pertemuan 13** untuk memaparkan progres dan **Pertemuan 15** untuk presentasi akhir. Di luar keduanya, Anda bekerja mandiri dan dapat berkonsultasi pada jam konsultasi dosen.

2 Topik dan dataset Anda

Setiap mahasiswa mendapat domain dan tantangan metodologi yang berbeda, sehingga tidak ada dua proyek yang sama.

Kolom terakhir adalah bagian terpenting: tantangan utama yang **wajib** Anda bahas di laporan. Tantangan itu dipilih karena paling sering menjebak pada jenis data tersebut.

NIM	Nama	Topik	Dataset	Jenis tugas	Tantangan utama
D082261005	Amirul Mukmin	Prediksi readmisi pasien diabetes dalam 30 hari	Diabetes 130-US Hospitals 1999–2008 (UCI)	Klasifikasi	Banyak fitur kategorikal dan nilai hilang; satu pasien punya banyak kunjungan, jadi wajib grouped k-fold.
D082261006	Bertold Maspa	Deteksi transaksi kartu kredit fraud	Credit Card Fraud Detection (Kaggle)	Klasifikasi tak seimbang	Kelas fraud sangat langka; bandingkan class weight vs resampling di dalam fold; gunakan PR-AUC.
D082261036	Chairul Muluk Kahar	Prediksi mahasiswa putus studi	Predict Students' Dropout and Academic Success (UCI)	Klasifikasi multi-kelas	Fitur akhir semester berisiko bocor; analisis keadilan antar kelompok mahasiswa.
D082261021	Fadhilah Eka Rahayu Amrullah	Analisis sentimen ulasan berbahasa Indonesia	SmSA, IndoNLU (Hugging Face)	Klasifikasi teks	TF-IDF + regresi logistik vs IndoBERT; analisis kesalahan pada sarkasme atau campuran bahasa.
D082261026	Fadil Ilham Tahir	Peramalan peminjaman sepeda per jam	Bike Sharing Dataset (UCI)	Regresi deret waktu	Validasi berurutan waktu; fitur lag, jam, dan cuaca; bandingkan dengan naive forecast.
D082261029	Julian Eugenio Boli	Prediksi harga rumah	House Prices: Advanced Regression Techniques (Kaggle)	Regresi	Fitur banyak, data sedikit; L1 vs L2 vs gradient boosting; outlier dan transformasi target.
D082261017	Muh Fauzi Ramadhan Nugraha	Segmentasi pelanggan ritel	Online Retail II (UCI)	Clustering	Fitur RFM; pilih jumlah klaster dengan silhouette dan interpretasi bisnis; evaluasi tanpa label.
D082261018	Muhammad Alif Qadri	Peramalan konsentrasi PM2.5	Beijing Multi-Site Air Quality (UCI)	Regresi deret waktu	Nilai hilang pada sensor; validasi berurutan waktu; uji model di stasiun lain (pergeseran distribusi).
D082261022	Nurrahmah Agusnaya	Prediksi risiko penyakit kardiovaskular	Cardiovascular Disease Dataset (Kaggle)	Klasifikasi	Bersihkan nilai pemeriksaan tak masuk akal; metrik dari sudut skrining (recall); interpretasi model.
D082261031	Nursoleharizkki	Prediksi churn pelanggan telekomunikasi	Telco Customer Churn (Kaggle)	Klasifikasi tak seimbang	Ambang keputusan berdasarkan biaya retensi vs kehilangan pelanggan; faktor penyebab churn.

Tautan diperiksa pada 3 November 2026. Dataset Kaggle memerlukan akun Kaggle (gratis). Untuk SmSA, pilih konfigurasi `smsa` pada IndoNLU.

Ketentuan dataset

- Anda boleh mengajukan pergantian topik yang lebih relevan dengan rencana tesis paling lambat akhir minggu ke-1, dengan persetujuan dosen. Dataset pengganti minimal 1.000 baris dan 5 fitur, publik atau dengan izin penggunaan yang jelas, dan bukan dataset “mainan” (Iris, Titanic, MNIST).
- Topik dan dataset tidak boleh sama dengan mahasiswa lain.
- Data pribadi harus dianonimkan sesuai UU No. 27 Tahun 2022 tentang Pelindungan Data Pribadi.

3 Peta jalan proyek

Tujuh tahap, dua titik temu. Empat tahap pertama harus selesai sebelum Pertemuan 13.

Bayangkan proyek Anda sebagai dua babak. Babak pertama membangun fondasi: memahami masalah, memahami data, dan yang paling penting, menetapkan cara mengevaluasi yang jujur. Kesalahan di babak ini mahal, karena semua hasil setelahnya ikut salah. Itulah sebabnya Pertemuan 13 ditempatkan tepat setelah baseline: dosen dan teman sekelas dapat menangkap kebocoran data atau skema validasi yang keliru sebelum Anda membangun model yang lebih rumit.

Babak kedua adalah tempat Anda mencoba model yang lebih kuat, mendiagnosis perilakunya, dan menganalisis kesalahannya. Hasilnya Anda pertanggungjawabkan pada Pertemuan 15.



Kotak bergaris putus-putus = luaran tertulis (laporan akhir + notebook), dikumpulkan pada Pertemuan 16.

Gambar 1. Peta jalan proyek: tahap 1–4 dipaparkan pada Pertemuan 13, tahap 5–7 dipertanggungjawabkan pada Pertemuan 15.

Struktur notebook yang disarankan

Susun notebook Anda mengikuti tahap di atas. Dosen akan menjalankan ulang notebook dari sel pertama sampai terakhir, jadi pastikan urutannya rapi dan seed acak ditetapkan di awal.

00	**Pengaturan:** import pustaka, `SEED = 42`, versi pustaka yang dipakai
01	**Rumusan masalah:** sel markdown berisi konteks, target, dan metrik utama
02	**Muat data & EDA:** statistik deskriptif, distribusi target, nilai hilang, grafik
03	**Pembagian data:** pisahkan data uji, simpan, dan jangan disentuh lagi
04	**Pipeline praproses + baseline:** hasil cross-validation
05	**Model lanjutan + tuning:** minimal dua model, tabel perbandingan
06	**Diagnosis:** learning curve, bias–varians
07	**Evaluasi final:** satu kali pada data uji
08	**Interpretasi & analisis kesalahan**
09	**Kesimpulan, keterbatasan, risiko etis**

4 Panduan hands-on, tahap demi tahap

Setiap tahap: apa yang harus dicapai, jebakan yang harus dihindari, dan kode yang bisa Anda sesuaikan.

Potongan kode di bab ini memakai contoh klasifikasi biner dengan kolom target bernama `target`. Ganti nama kolom, metrik, dan skema validasi sesuai topik Anda. Catatan khusus untuk regresi, deret waktu, teks, dan clustering ada di akhir bab.

Tahap 1 · Rumuskan masalah dan pilih metrik

Sebelum membuka data, jawab tiga pertanyaan secara tertulis. Siapa yang akan memakai hasil model ini? Keputusan apa yang mereka ambil berdasarkan prediksinya? Dan kesalahan jenis mana yang lebih merugikan mereka? Jawaban pertanyaan ketiga menentukan metrik utama Anda.

> **Template satu kalimat**
>
> "Model ini membantu *[pengguna]* untuk *[keputusan]* dengan memprediksi *[target]* dari *[fitur]*. Kesalahan paling mahal adalah *[FP/FN/galat besar]*, sehingga metrik utama adalah *[metrik]*."

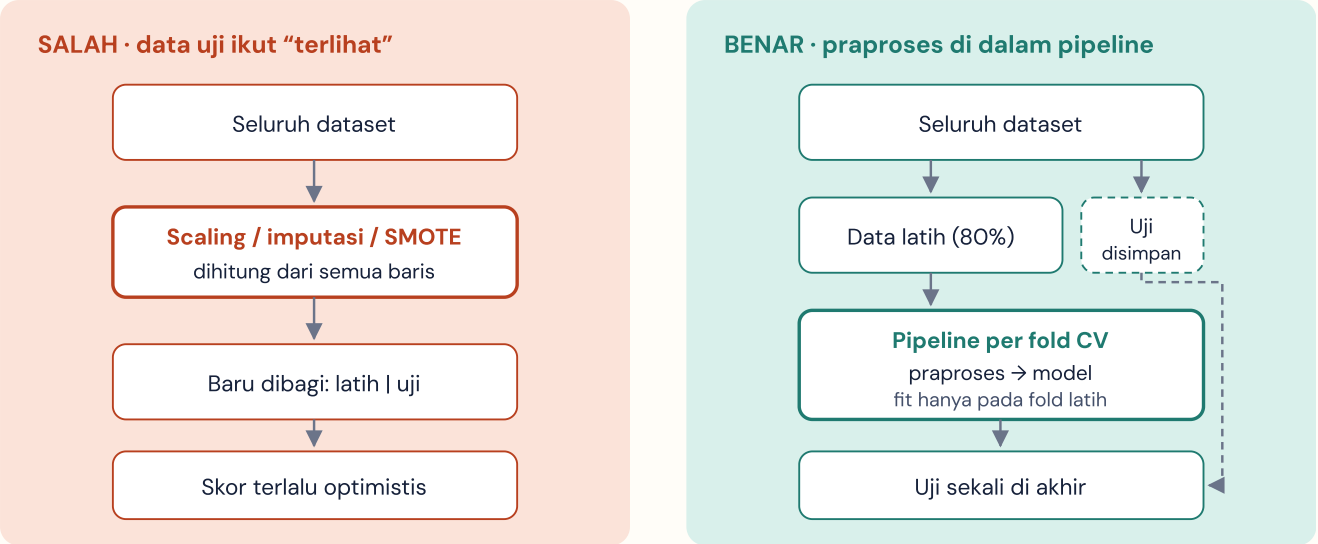
Situasi di masalah Anda	Metrik utama	Contoh topik
Kasus positif yang terlewat sangat mahal (FN mahal)	Recall, F2	Kardiovaskular, readmisi diabetes
Alarm palsu sangat mahal (FP mahal)	Presisi	Intervensi berbiaya tinggi
Kelas positif sangat langka	PR-AUC (average precision)	Fraud, churn
Kelas relatif seimbang, butuh ringkasan lintas ambang	ROC-AUC, F1	Sentimen
Lebih dari dua kelas	Macro-F1 + confusion matrix	Putus studi (3 kelas)
Regresi, galat dijelaskan dalam satuan asli	MAE	Peminjaman sepeda
Regresi, galat besar sangat merugikan	RMSE	PM2.5, harga rumah (RMSE log)
Tanpa label	Silhouette + interpretasi	Segmentasi pelanggan

Ingat: akurasi hampir tidak pernah menjadi metrik utama yang baik pada data tak seimbang. Jika hanya 1% transaksi yang fraud, model yang selalu menebak "bukan fraud" mencapai akurasi 99% dengan recall 0%.

Tahap 2 · Eksplorasi dan praproses data

Eksplorasi data bertujuan menemukan apa yang akan memengaruhi keputusan Anda berikutnya: seberapa tak seimbang targetnya, kolom mana yang banyak kosong, nilai apa yang tidak masuk akal, dan fitur mana yang mungkin baru tersedia setelah kejadian yang ingin diprediksi. Fitur seperti itu harus dibuang karena membocorkan jawaban.

Aturan terpenting di tahap ini sederhana namun sering dilanggar: **semua langkah praproses yang "belajar" dari data** (imputasi, scaling, encoding, seleksi fitur, resampling) harus dilakukan **di dalam pipeline**, sehingga ia hanya belajar dari data latih pada setiap fold.



Gambar 2. Kebocoran praproses. Di kiri, rata-rata dan simpangan untuk scaling (atau titik sintetis SMOTE) ikut dipengaruhi data uji. Di kanan, data uji disisihkan sejak awal dan setiap langkah praproses dipelajari ulang di dalam setiap fold.

KODE 1 · PEMBAGIAN DATA DAN PIPELINE PRAPROSES

```
import numpy as np, pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.pipeline import Pipeline
from sklearn.compose import ColumnTransformer, make_column_selector
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.impute import SimpleImputer

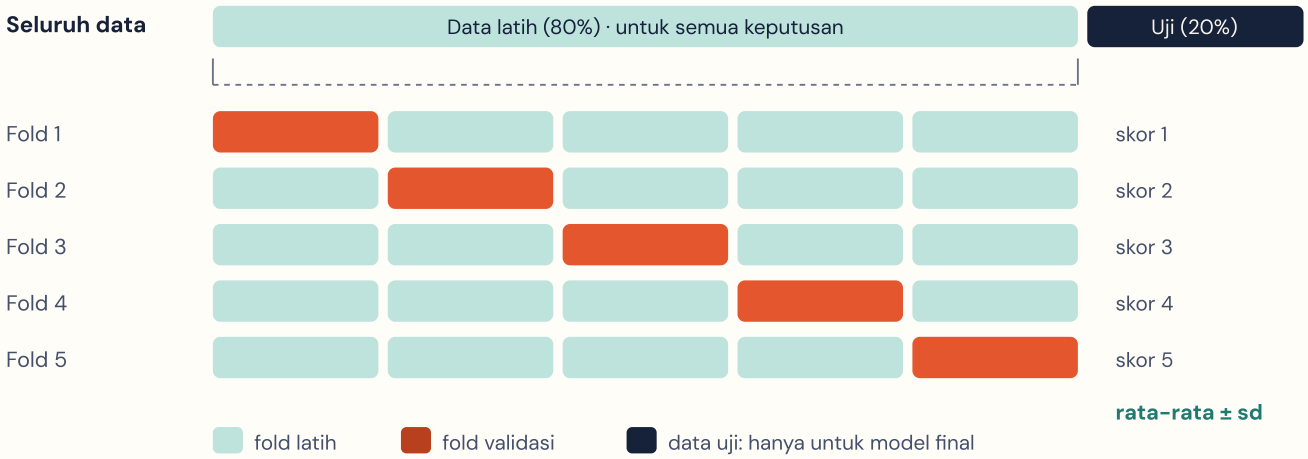
SEED = 42
df = pd.read_csv("data.csv")
X = df.drop(columns=["target"])            # buang juga kolom ID dan fitur yang bocor
y = df["target"]

# Data uji disisihkan SEKARANG, sebelum eksplorasi lebih jauh
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, stratify=y, random_state=SEED)

prep = ColumnTransformer([
    ("num", Pipeline([("imp", SimpleImputer(strategy="median")),
                      ("sc", StandardScaler())]),
     make_column_selector(dtype_include="number")),
    ("cat", Pipeline([("imp", SimpleImputer(strategy="most_frequent")),
                      ("oh", OneHotEncoder(handle_unknown="ignore",
                                           sparse_output=False))]),
     make_column_selector(dtype_exclude="number")),
])
```

Tahap 3 · Rancang skema validasi

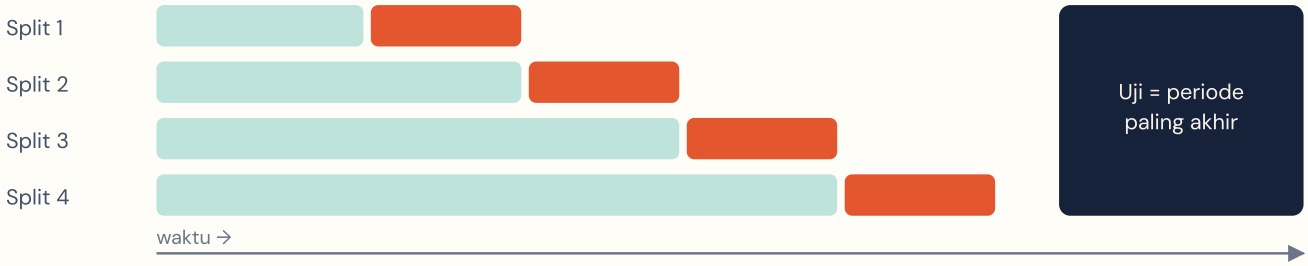
Skema validasi adalah "aturan ujian" untuk model Anda. Data uji (20%) disisihkan dan hanya dipakai sekali di akhir. Seluruh keputusan lain, yaitu memilih model, mengatur hyperparameter, dan membandingkan praproses, dibuat dengan **k-fold cross-validation** pada data latih. Hasilnya dilaporkan sebagai rata-rata ± simpangan baku dari k fold, sehingga terlihat seberapa stabil model Anda.



Gambar 3. Hold-out + 5-fold cross-validation. Setiap fold bergiliran menjadi data validasi; data uji tidak pernah ikut dalam proses ini.

Varian k-fold yang tepat bergantung pada struktur data Anda. Memilih varian yang salah adalah salah satu sumber kebocoran yang paling halus.

TimeSeriesSplit · jendela latih melebar, validasi selalu di masa depan



Gambar 4. Untuk deret waktu, data tidak boleh diacak. Model hanya boleh belajar dari masa lalu untuk memprediksi masa depan.

Struktur data	Skema	Berlaku untuk
Baris independen, kelas tak seimbang	`StratifiedKFold`	Bertold, Chairul, Fadhilah, Nurrahmah, Nursoleharizkki
Satu subjek punya banyak baris	`GroupShuffleSplit` + `GroupKFold`	Amirul (kelompok = ID pasien)
Data berurutan waktu	Uji = periode terakhir + `TimeSeriesSplit`	Fadil, Alif
Regresi biasa	`KFold(shuffle=True)`	Julian
Tanpa label	Stabilitas klaster pada beberapa seed dan sub-sampel	Fauzi

KODE 2 · VARIAN SKEMA VALIDASI

```
from sklearn.model_selection import (StratifiedKFold, GroupKFold,
                                     GroupShuffleSplit, TimeSeriesSplit)

# (a) Klasifikasi biasa
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=SEED)

# (b) Banyak baris per pasien: pasien yang sama tidak boleh ada di latih DAN uji
groups = df["patient_nbr"]
gss = GroupShuffleSplit(n_splits=1, test_size=0.2, random_state=SEED)
idx_train, idx_test = next(gss.split(X, y, groups))
cv = GroupKFold(n_splits=5)       # saat memanggil cross_validate: groups=groups.iloc[idx_train]

# (c) Deret waktu: urutkan dulu menurut waktu, lalu potong tanpa diacak
df = df.sort_values("datetime")
batas = int(len(df) * 0.8)
train_df, test_df = df.iloc[:batas], df.iloc[batas:]
cv = TimeSeriesSplit(n_splits=5)
```

Tahap 4 · Bangun baseline

Baseline adalah titik acuan. Tanpanya, angka seperti "F1 = 0,72" tidak bermakna: apakah itu bagus atau hanya sedikit lebih baik dari menebak? Gunakan model sederhana yang cepat dilatih dan mudah dijelaskan, misalnya regresi logistik atau linear. Untuk deret waktu, baseline wajibnya adalah **naive forecast** (nilai periode sebelumnya). Hasil baseline inilah yang Anda paparkan pada **Pertemuan 13**.

KODE 3 · BASELINE DENGAN CROSS-VALIDATION

```
from sklearn.model_selection import cross_validate
from sklearn.linear_model import LogisticRegression

baseline = Pipeline([("prep", prep),
                     ("model", LogisticRegression(max_iter=1000))])

metrik = ["f1", "recall", "average_precision"]   # average_precision = PR-AUC
hasil = cross_validate(baseline, X_train, y_train, cv=cv, scoring=metrik)
for m in metrik:
    s = hasil[f"test_{m}"]
    print(f"{m:>18}: {s.mean():.3f} ± {s.std():.3f}")
```

Catat hasil setiap model dalam satu tabel yang terus Anda tambah. Tabel ini akan menjadi inti bagian Hasil di laporan.

Model	Praproses khusus	Metrik utama (CV, rata-rata ± sd)	Metrik pendukung	Catatan
Regresi logistik (baseline)	—	0,___ ± 0,___	…	…
Random forest	class_weight	0,___ ± 0,___	…	…
Gradient boosting (tuned)	SMOTE di pipeline	0,___ ± 0,___	…	…

Tahap 5 · Model lanjutan dan tuning

Pilih minimal **dua** model lanjutan yang punya alasan kuat untuk data Anda. Pada data tabular, model berbasis pohon seperti random forest dan gradient boosting biasanya kandidat terkuat. Pada teks, bandingkan dengan model pralatih. Tuning hyperparameter dilakukan dengan cross-validation pada data latih. Data uji tetap tidak disentuh.

Jika data Anda tak seimbang, ada dua jalur yang bisa dibandingkan: memberi bobot kelas (`class_weight="balanced"`) atau resampling seperti SMOTE. Resampling harus berada di dalam pipeline `imblearn` agar hanya terjadi pada fold latih.

KODE 4 · RESAMPLING DI DALAM PIPELINE DAN TUNING HYPERPARAMETER

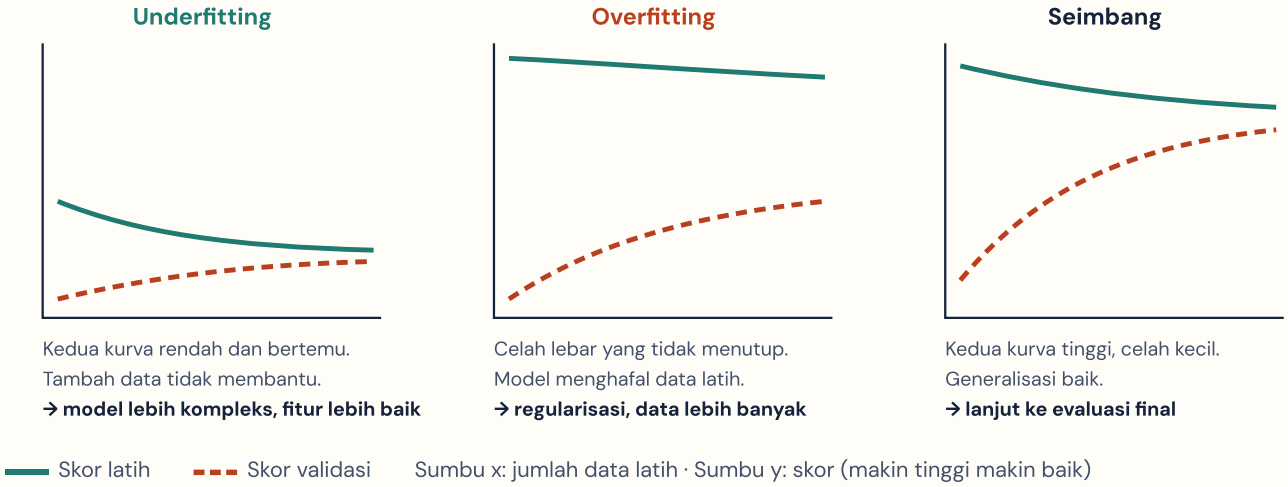
```
from imblearn.pipeline import Pipeline as ImbPipeline
from imblearn.over_sampling import SMOTE
from sklearn.ensemble import RandomForestClassifier, HistGradientBoostingClassifier
from sklearn.model_selection import RandomizedSearchCV

# Model lanjutan 1: random forest + SMOTE (SMOTE hanya berjalan pada fold latih)
model_rf = ImbPipeline([("prep", prep),
                        ("smote", SMOTE(random_state=SEED)),
                        ("model", RandomForestClassifier(random_state=SEED))])

# Model lanjutan 2: gradient boosting dengan pencarian hyperparameter
pipe_gb = Pipeline([("prep", prep),
                    ("model", HistGradientBoostingClassifier(random_state=SEED))])
ruang = {
    "model__learning_rate": [0.03, 0.1, 0.3],
    "model__max_depth": [3, 6, None],
    "model__l2_regularization": [0.0, 0.1, 1.0],   # regularisasi L2
}
search = RandomizedSearchCV(pipe_gb, ruang, n_iter=15, cv=cv,
                            scoring="average_precision", random_state=SEED)
search.fit(X_train, y_train)
print(search.best_params_, round(search.best_score_, 3))
```

Tahap 6 · Evaluasi dan diagnosis

Skor saja tidak cukup; Anda harus bisa menjelaskan **mengapa** model berperilaku seperti itu. Alat utamanya adalah **learning curve**: skor pada data latih dan data validasi sebagai fungsi jumlah data latih. Bentuk kedua kurva memberi tahu Anda masalahnya dan apa yang harus dilakukan.



Gambar 5. Tiga pola learning curve (ilustrasi skematis, bukan data nyata) dan tindakan yang sesuai.

Setelah model final dipilih berdasarkan cross-validation, barulah Anda membuka data uji. **Satu kali.** Jika skor uji jauh lebih buruk dari skor CV, jangan kembali dan menyetel ulang model berdasarkan data uji; laporkan dan analisis perbedaannya.

KODE 5 · LEARNING CURVE DAN EVALUASI FINAL PADA DATA UJI

```
from sklearn.model_selection import LearningCurveDisplay
from sklearn.metrics import classification_report, ConfusionMatrixDisplay

final = search.best_estimator_          # sudah dilatih ulang pada seluruh data latih

LearningCurveDisplay.from_estimator(
    final, X_train, y_train, cv=cv, scoring="average_precision",
    train_sizes=np.linspace(0.1, 1.0, 5))

# ---- Hanya dijalankan SEKALI, setelah semua keputusan diambil ----
y_pred = final.predict(X_test)
print(classification_report(y_test, y_pred))
ConfusionMatrixDisplay.from_predictions(y_test, y_pred)
```

Tahap 7 · Analisis kesalahan, interpretasi, dan etika

Bagian ini yang membedakan laporan biasa dari laporan yang baik. Ambil prediksi yang salah, lalu cari polanya: apakah kesalahan menumpuk pada kelompok tertentu, rentang nilai tertentu, atau jenis teks tertentu? Lalu jelaskan fitur apa yang paling diandalkan model, dan apakah itu masuk akal secara domain.

KODE 6 · KEPENTINGAN FITUR DAN ANALISIS KESALAHAN

```
from sklearn.inspection import permutation_importance

imp = permutation_importance(final, X_test, y_test, scoring="average_precision",
                             n_repeats=10, random_state=SEED)
penting = pd.Series(imp.importances_mean, index=X_test.columns)
print(penting.sort_values(ascending=False).head(10))

# Bandingkan profil prediksi yang salah dengan yang benar
analisis = X_test.assign(aktual=y_test, prediksi=y_pred)
salah = analisis[analisis["aktual"] ≠ analisis["prediksi"]]
benar = analisis[analisis["aktual"] == analisis["prediksi"]]
print(salah.describe(include="all"))
print(benar.describe(include="all"))
```

Empat pertanyaan etis yang wajib dijawab di laporan

1. Apakah kinerja model berbeda untuk kelompok yang berbeda (misalnya jenis kelamin, usia, wilayah)? Hitung metrik utama per kelompok.
2. Siapa yang dirugikan jika model salah, dan seberapa besar kerugiannya?
3. Apakah ada fitur yang sensitif atau bisa menjadi proksi diskriminasi?
4. Bagaimana seharusnya model dipakai: otomatis, atau sebagai alat bantu bagi manusia yang tetap memutuskan?

Catatan untuk jenis tugas lain

Regresi

Ganti `StratifiedKFold` dengan `KFold(shuffle=True)` dan scoring dengan `"neg_mean_absolute_error"` atau `"neg_root_mean_squared_error"`. Plot residual terhadap prediksi. Untuk harga rumah, pertimbangkan memodelkan log harga.

Deret waktu

Bangun fitur lag dan kalender (jam, hari, musim) **hanya dari masa lalu**. Bandingkan setiap model dengan naive forecast. Laporkan galat per jam atau per musim.

Teks

Baseline: `TfidfVectorizer` + `LogisticRegression` dalam satu pipeline. Model lanjutan: fine-tuning IndoBERT (Hugging Face Transformers, GPU Colab). Analisis kesalahan dengan membaca contoh kalimat yang salah.

Clustering

Bangun fitur RFM, lakukan scaling, bandingkan beberapa nilai k dengan `silhouette_score`. Evaluasi juga dengan interpretasi: beri nama tiap klaster dan usulkan tindakan bisnisnya.

5 Luaran dan struktur laporan

Empat luaran: proposal, notebook, laporan akhir, dan presentasi.

Luaran	Format	Isi
Proposal	PDF, 1–2 halaman	Rumusan masalah, sumber dataset, metrik utama yang direncanakan beserta alasannya.
Notebook	.ipynb atau tautan Colab/GitHub	Kode lengkap dan berkomentar, mengikuti struktur di Bab 3, dapat dijalankan ulang dari awal.
Laporan akhir	PDF, 8–12 halaman	Format artikel ilmiah, struktur di bawah.
Presentasi	10 menit + 5 menit tanya jawab	Maksimal 10 slide, dibawakan pada Pertemuan 15.

Struktur laporan akhir

Tulis laporan seperti artikel ilmiah singkat. Pembaca harus bisa memahami apa yang Anda lakukan, mengapa, dan seberapa yakin Anda pada hasilnya, tanpa membuka notebook.

1. **Abstrak** (maksimal 200 kata).
2. **Pendahuluan:** konteks, rumusan masalah, kontribusi.
3. **Tinjauan pustaka singkat:** minimal 5 referensi, 3 di antaranya artikel jurnal atau konferensi 5 tahun terakhir.
4. **Data dan metodologi:** dataset, praproses, skema validasi, model.
5. **Hasil:** tabel perbandingan model, learning curve, metrik pada data uji.
6. **Pembahasan:** diagnosis bias–varians, analisis kesalahan, interpretasi.
7. **Etika dan keterbatasan.**
8. **Kesimpulan dan saran.**
9. **Daftar pustaka** (gaya APA atau IEEE, konsisten).
10. **Lampiran:** deklarasi penggunaan alat AI.

Beri nama file `NIM_Nama_ProyekML.pdf` dan `NIM_Nama_ProyekML.ipynb`, lalu kumpulkan melalui [LMS / platform pengumpulan].

6 Jadwal dan dua pertemuan kelas

Tugas dibahas di kelas pada Pertemuan 13 (progres) dan Pertemuan 15 (presentasi akhir); laporan dikumpulkan pada Pertemuan 16.



Gambar 6. Lini waktu proyek: lima minggu pengerjaan, presentasi pada Pertemuan 15, lalu laporan akhir dan notebook dikumpulkan pada Pertemuan 16.

Minggu	Kegiatan	Luaran	Tenggat
1	Konfirmasi topik dan dataset	Proposal	[tanggal]
2	Eksplorasi data, praproses, skema validasi	—	—
3	**Pertemuan 13: Progres**	Notebook sementara + slide progres	Pertemuan 13
4	Model lanjutan, tuning, tindak lanjut umpan balik	—	—
5	Evaluasi akhir, analisis kesalahan, etika	—	—
6	**Pertemuan 15: Presentasi akhir**	Slide presentasi	Pertemuan 15
—	**Pertemuan 16: Pengumpulan**	Laporan akhir + notebook	Pertemuan 16

Mempersiapkan Pertemuan 13 (progres)

Anggap pertemuan ini sebagai pemeriksaan fondasi. Siapkan paparan singkat, maksimal 5 slide, yang menunjukkan rumusan masalah dan metrik utama Anda, temuan penting dari eksplorasi data, skema validasi beserta cara Anda mencegah kebocoran, hasil baseline, dan rencana model lanjutan. Sampaikan juga kendala yang Anda hadapi; justru itu yang paling berguna untuk dibahas. Pertemuan ini tidak dinilai terpisah, tetapi umpan baliknya harus Anda tindak lanjuti dan jelaskan di laporan akhir.

Mempersiapkan Pertemuan 15 (presentasi akhir)

Di sini Anda mempertanggungjawabkan hasil. Alur yang disarankan: masalah dan mengapa penting, data dan skema validasi, perbandingan baseline dan model lanjutan, diagnosis dan hasil pada data uji, analisis kesalahan, lalu risiko etis dan kesimpulan. Bersiaplah menjelaskan setiap keputusan metodologi dan bagian kode yang ditanyakan.

Keterlambatan pengumpulan dikenai pengurangan 10% per hari, kecuali dengan alasan yang disetujui dosen sebelum tenggat.

7 Rubrik penilaian

Total 100. Separuh nilai ada pada validasi, evaluasi, dan analisis.

Komponen	Bobot	Sangat baik (A)	Cukup (B–C)	Kurang (D–E)
Proposal dan rumusan masalah	10%	Masalah nyata; target dan metrik dijustifikasi dengan biaya kesalahan	Masalah jelas, justifikasi metrik umum	Masalah kabur atau tanpa metrik
Eksplorasi dan praproses	10%	EDA bermakna; praproses di dalam pipeline	EDA standar; sebagian praproses di luar pipeline	EDA minim; praproses bocor
Skema validasi	20%	Sesuai struktur data, bebas kebocoran, data uji dipakai sekali	Benar tetapi kurang dijustifikasi	Ada kebocoran atau tanpa data uji terpisah
Pemodelan	15%	Baseline + 2 model lanjutan, tuning sistematis	Model lengkap, tuning seadanya	Tanpa baseline atau hanya satu model
Evaluasi dan diagnosis	15%	Metrik tepat dengan ketidakpastian, learning curve, diagnosis bias–varians	Metrik tepat tanpa diagnosis	Hanya akurasi pada data tak seimbang
Analisis kesalahan, interpretasi, etika	15%	Pola kesalahan dan risiko etis dianalisis tajam, dengan mitigasi	Ada analisis tetapi dangkal	Tidak ada analisis
Laporan dan notebook	10%	Rapi, berargumen, referensi memadai, notebook dapat dijalankan ulang	Lengkap tetapi kurang rapi	Tidak lengkap atau notebook gagal dijalankan
Presentasi dan tanya jawab	5%	Jelas, tepat waktu, menguasai jawaban	Cukup jelas	Tidak menguasai materi



Warna gelap = komponen metodologi evaluasi dan analisis (50% dari nilai). P = presentasi (5%).

Gambar 7. Proporsi bobot rubrik.

8 Integritas akademik dan penggunaan AI

Anda boleh dibantu, asalkan jujur tentang bantuan itu dan memahami setiap bagian pekerjaan Anda.

Proyek ini dikerjakan **sendiri**. Berdiskusi tentang konsep dengan teman sekelas diperbolehkan dan bahkan dianjurkan, tetapi berbagi kode atau laporan tidak. Kode dari tutorial, Kaggle, atau GitHub boleh Anda pakai bila sumbernya dicantumkan di notebook.

Alat AI seperti ChatGPT, Claude, atau Copilot boleh dipakai untuk membantu menulis kode atau memperbaiki bahasa, dengan dua syarat. Pertama, penggunaannya dideklarasikan di lampiran laporan: alat apa dan untuk bagian apa. Kedua, Anda memahami dan dapat menjelaskan setiap baris kode dan setiap klaim di laporan saat tanya jawab. Analisis, interpretasi, dan kesimpulan harus merupakan pemikiran Anda sendiri.

> **Pelanggaran**
>
> Plagiarisme, data atau hasil yang direkayasa, serta kode yang tidak dapat Anda jelaskan dinilai nol untuk komponen terkait dan diproses sesuai peraturan akademik [universitas].

Bacaan pendukung

- Géron, A. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. O'Reilly. Bab tentang proyek end-to-end sangat dekat dengan alur proyek ini.
- Hastie, T., Tibshirani, R., & Friedman, J. *The Elements of Statistical Learning*. Springer. Rujukan teori bias–varians dan validasi silang.
- Dokumentasi scikit-learn, terutama bagian *Cross-validation*, *Pipelines and composite estimators*, dan *Common pitfalls and recommended practices*.

L Daftar periksa sebelum mengumpulkan

Centang setiap butir. Jika ada yang belum, perbaiki dulu.

Data dan validasi

- [ ] Data uji dipisahkan di awal dan hanya dipakai sekali untuk model final.
- [ ] Semua imputasi, scaling, encoding, dan resampling ada di dalam pipeline.
- [ ] Tidak ada fitur yang baru tersedia setelah kejadian yang diprediksi.
- [ ] Skema validasi sesuai struktur data (stratified, grouped, atau berurutan waktu) dan alasannya dijelaskan.

Model dan evaluasi

- [ ] Ada satu baseline dan minimal dua model lanjutan.
- [ ] Metrik utama dijustifikasi dengan biaya kesalahan; akurasi bukan satu-satunya metrik.
- [ ] Hasil CV dilaporkan sebagai rata-rata ± simpangan baku.
- [ ] Ada learning curve dan diagnosis bias–varians.

Analisis dan etika

- [ ] Ada analisis pola kesalahan, bukan hanya angka.
- [ ] Ada interpretasi fitur penting yang dikaitkan dengan pengetahuan domain.
- [ ] Empat pertanyaan etis di Tahap 7 dijawab.
- [ ] Umpan balik dari Pertemuan 13 sudah ditindaklanjuti dan dijelaskan.

Berkas

- [ ] Notebook berjalan dari awal sampai akhir tanpa error (Restart & Run All).
- [ ] `SEED` ditetapkan dan versi pustaka dicatat.
- [ ] Laporan 8–12 halaman, minimal 5 referensi, dengan deklarasi penggunaan AI.
- [ ] Nama file mengikuti format `NIM_Nama_ProyekML`.